КУРСОВОЙ ПРОЕКТ

по дисциплине
«Предподготовка и анализ данных»

ОТЧЕТ

Рынок автомобилей Казахстана и позиция «Меркур Авто»

Январь — сентябрь 2019 года

Выполнил:
студент группы М26-555
Задорожний Илья Владимирович

2026

1. Введение

В проекте выполнены предподготовка и исследовательский анализ продаж автомобилей в Казахстане за январь — сентябрь 2019 года. Файл autokz2019.csv содержит 39 966 строк и 25 столбцов: компании, дилеры, марки, модели, технические характеристики, регионы, количество и стоимость продаж в долларах США.

Работа выполнена в контексте задачи автодилерского холдинга: оценить положение «Меркур Авто» на рынке и сравнить его показатели с общей выборкой. В одной тетради Jupyter последовательно проведены загрузка, очистка, проверка типов, расчет показателей и построение графиков. Итогом обработки стал файл autokz2019_clean.csv, пригодный для дальнейшего анализа и загрузки в BI-системы.

2. Актуальность

Качество данных влияет на сравнение компаний. Разные написания названий разделяют продажи на несколько групп, ошибки искажают распределения, повторы меняют объем рынка. Одна запись может описывать партию автомобилей, поэтому продажи нужно считать по сумме количества. Перед оценкой «Меркур Авто» необходимо очистить данные, проверить смысл показателей и обозначить ограничения.

3. Цель работы

Техническая цель работы — подготовить очищенный набор данных и воспроизводимую последовательность обработки в Jupyter Notebook. Аналитическая цель — описать структуру и динамику автомобильного рынка в представленной выборке, рассчитать долю «Меркур Авто», сравнить среднюю цену автомобиля и состав продаж с рыночными показателями, определить сильные и слабые стороны наблюдаемого положения компании.

4. Описание процесса очистки

CSV загружен с разделителем «точка с запятой» и десятичной запятой. Проверены типы, пропуски и повторы. По заданию удалены 18 698 полных повторов; пустых строк не обнаружено. Осталось 21 268 строк. Повторы проверя-

лись до удаления столбцов, чтобы сохранить записи, различавшиеся комплектацией, клиентом или дилером. Сохранен номер исходной строки.

Удалены семь полей, не используемых в основных расчетах: название дилерского центра, форма расчета, старый сегмент, сегмент Eng, локализация производства, тип клиента и модификация. Перед удалением из них извлечены сведения о гибридах и признак наличия Mercur Auto в имени дилера. Названия оставшихся столбцов переведены на английский. Удалены лишние пробелы, объединены явные варианты названий компаний, включая Mercur Auto и Mercur Autos. Число вариантов компаний сократилось с 40 до 33.

Страны производства представлены трехбуквенными кодами ALPHA-3. Топливо сведено к категориям F, D, E и HYB, коробки передач — к автоматической и механической. Обозначения полного, переднего и заднего привода приведены к единому виду. Категория 2WD сохранена отдельно, поскольку она не определяет ведущую ось. Названия регионов и областей приведены к единому регистру.

При проверке характеристик восстановлены сдвинутые поля объема и коробки в 27 строках Renault. У Chevrolet Niva исправлены 25 значений объема от 2,7 до 26,7 л: последовательный ряд ошибок заменен на преобладающее для этой модели значение 1,7 л. Это локальное допущение обработки. У электрического Jaguar запись «400 Л.С.» обозначает мощность, а у электробуса «88 KWH» — емкость батареи. Для электрического транспорта объем двигателя внутреннего сгорания задан нулем. Неизвестные характеристики сохранены как пропуски.

Количество и год выпуска преобразованы в целочисленный тип с поддержкой пропусков, цены — в числовой тип. Из года и месяца сформирована дата последнего календарного дня месяца, включая 28 февраля 2019 года. Она обозначает отчетный период, а не точный день сделки. Топливо, коробка, привод, сегмент и класс преобразованы в категориальный тип. Исходные столбцы года и месяца удалены.

Сохранен возврат Skoda Superb с количеством −1 и отрицательной стоимостью, а также крупные партии, включая 100 Skoda Octavia и 115 Lada 4x4. В этих строках количество согласуется со стоимостью. Шесть записей с неизвестным количеством оставлены в CSV, но исключены из расчета продаж. Экспорт отмечен отдельным признаком и исключен из анализа внутреннего рынка.

Проверено равенство цены, умноженной на количество, и итоговой стоимости с допуском в один цент.

Итоговый CSV содержит 21 268 строк и 22 столбца: кодировка UTF-8 с BOM, разделитель-запятая, десятичная точка, даты YYYY-MM-DD. После повторного чтения восстановлены типы и проверено совпадение значений и пропусков.

5. Выводы анализа рынка и позиции «Меркур Авто»

Внутренний объем очищенной выборки составляет 34 725 автомобилей с учетом одного возврата. Еще 440 автомобилей относятся к экспорту. Стоимость внутренних продаж равна 801,70 млн USD, средняя цена автомобиля — 23 087,05 USD. Средняя рассчитана как отношение суммы стоимости к сумме количества, поэтому крупные партии учитываются с полным весом. Медианная цена положительных продаж составляет 16 000 USD. Различие среднего и медианы связано с присутствием дорогих автомобилей и коммерческой техники.

По количеству лидируют Lada — 11 085 автомобилей, Hyundai — 4 987 и Toyota — 3 636. По стоимости продаж первое место занимает Toyota. Крупнейшая модель — Lada Granta, 3 663 автомобиля. Алматы и Нур-Султан вместе обеспечивают 38,49% внутреннего объема. Основные сегменты — легковые автомобили и внедорожники. Максимальное количество приходится на июль — 4 432 автомобиля, минимальное на январь — 2 953. Девяти месяцев одного года недостаточно для вывода об устойчивой сезонности.

По нормализованному полю компании «Меркур Авто» учтено 394 автомобиля на 15,12 млн USD. Компания занимает 11-е место по количеству в очищенной выборке. Ее доля составляет 1,13% автомобилей и 1,89% стоимости продаж. Средняя цена равна 38 379,52 USD. При приведении рынка к структуре брендов «Меркур Авто» сопоставимая рыночная средняя составляет 37 809,71 USD, а превышение цены компании сокращается до 1,51%. Следовательно, большая часть исходного различия связана с составом брендов.

Volkswagen дает 74,62% объема компании, Алматы — 63,71%. Доля «Меркур Авто» внутри Volkswagen составляет 28,05%; все продажи Audi и Porsche в этой выборке отнесены к компании. Легковые автомобили занимают 59,39% ее объема против 43,22% рынка, внедорожники — 36,80% против

40,45%. Сильная сторона наблюдаемого положения — присутствие в дорогих брендах и более высокая доля стоимости по сравнению с количеством. Ограничения — небольшой общий объем, концентрация на одном бренде и городе и слабое присутствие в коммерческом сегменте. Данных о прибыли, марже и затратах нет, поэтому эти показатели не оценивают финансовую эффективность.

На интерпретацию динамики влияет различие полей компании и дилера. С июня продажи Volkswagen встречаются у дилеров Mercur Auto, но записаны под компанией Volkswagen Group Rus. Такие строки не попадают в отбор по компании «Меркур Авто», хотя имя дилерского центра сохраняется. По имени дилера получается 712 автомобилей, по объединению двух условий без повторного учета — 813. Это разные способы отбора записей; принадлежность всех дилеров одной организации в файле не установлена. Поэтому снижение ряда компании не доказывает падения реальных продаж автоцентра.

Удаление полных повторов также существенно влияет на результат. Если сохранить все одинаковые исходные записи, внутренний объем составит 51 955 автомобилей, а доля «Меркур Авто» по компании — 1,25% вместо 1,13%. Без идентификаторов сделок нельзя окончательно различить дубли выгрузки и одинаковые продажи. Полученные выводы относятся к указанному периоду, составу выборки и принятому сценарию обработки.

6. Ссылка на код

Код, результаты и графики находятся в тетради 03_Zadorozhnii_M26-555.ipynb. Репозиторий содержит исходный и очищенный CSV. Для воспроизведения нужно установить зависимости и выполнить ячейки сверху вниз. Последняя ячейка сохраняет итоговые данные.

Открыть тетрадь с кодом на GitHub
https://github.com/Xlemon5/autokz2019-analysis